# **Streaming Data Pipeline**

jaehyeuk.oh@hpcnt.com

## 배경

Hyperconnect 에서는 Spark Streaming 을

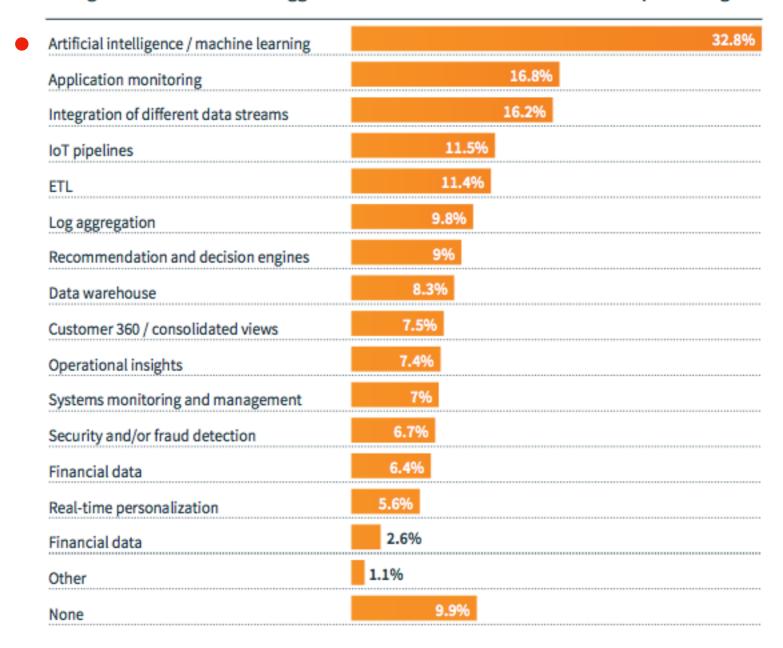
Fraud detection
Rule-based Alerting
Realtime User Segmentation and A/B Testing
Matching

등에 활용해 왔습니다만,

Low Latency 구현 최적화 Failover 이후 State 유실 Python 으로 구현된 Model 의 Scala 로의 재구현

등에 어려움이 있었습니다.

# Within the next 12 months, which two types of application or use cases in your organization will see the biggest increase in their use of real-time data processing?



Low Latency 등 성능 이슈에 대응 하기 위한 목적으로 Native Streaming Framework 인 Flink 를 도입했고
Python Model 을 효과적으로 Streaming 에 적용하기 위해 Native Python 을 지원하는 방법을
Beam on Flink Runner 에서 찾았습니다.

여전히 Experimental 한 부분이 있지만, 빠르게 쓸만한 모습이 될 것으로 기대됩니다.

Tutorial 에서는 Direct Runner 를 사용하여 진행합니다.

이번 튜토리얼을 통해

Transform, Time, Window, Trigger, State 등

Streaming Data Application 의 주요 개념을 익히고,

Python 환경에서 실습하여 익숙해지는 계기가 되기를 기대합니다.

- 1. Qwiklab 환경에서 Runner 실행
- 2. Streaming Data Application 개념
- 3. Local 환경에서 Lab 실행

## Lab 0. 환경 설정

# https://taw.qwiklabs.com/classrooms/2193

pycon##@gmail.com / pycon##

- 1. DataProc Cluster 생성
- 2. Master 접속 후 기본 설정
- 3. Direct / Dataflow / Flink Runner 실행 및 확인

## https://taw.qwiklabs.com/classrooms/2193

- 1. Project ID 확인 : qwiklabs-gcp-...
- 2. Cloud Storage Bucket 생성: pycon##-bucket
- 3. DataProc Cluster 생성
- !!! Component gateway, Project access 에 check 확인

#### --initialization-actions

gs://da-beam-flink/docker/docker.sh

gs://da-beam-flink/flink/flink.sh

gs://da-beam-flink/beam/beam.sh

#### --metadata

beam-job-service-snapshot=gs://da-beam-flink/beam-runners-flink-1.7-job-server-2.14.0-SNAPSHOT.jar

beam-image-enable-pull=true

beam-image-repository=gcr.io/azar-production-de-main/beam-flink

beam-image-version=v2.14.0

flink-start-yarn-session=true

flink-snapshot-url=https://archive.apache.org/dist/flink/flink-1.7.2/flink-1.7.2-bin-hadoop28-scala\_2.11.tgz

## https://taw.qwiklabs.com/classrooms/2193

#### 1. Master 접속 후 기본 설정

```
sudo apt install python-pip
sudo pip install apache-beam==2.14.0
sudo pip install six==1.12.0
sudo pip install google-cloud
sudo pip install google-cloud-storage
sudo pip install google-cloud-dataflow
sudo pip install "apache-beam[gcp]"
```

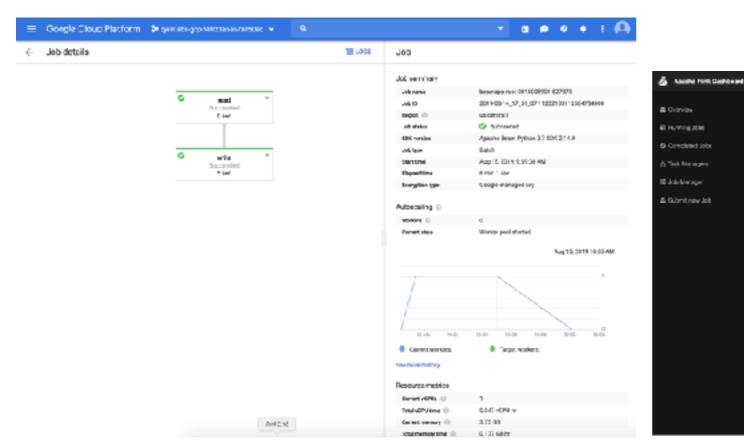
git clone <a href="https://github.com/JaehyeukOO/pypipeline-tutorial.git">https://github.com/JaehyeukOO/pypipeline-tutorial.git</a>

# https://taw.qwiklabs.com/classrooms/2193

#### 1. Direct / Dataflow / Flink Runner 실행 및 확인

```
gsutil cp gs://da-beam-flink/1_direct_run.py .
gsutil cp gs://da-beam-flink/2_dataflow_run.py .
gsutil cp gs://da-beam-flink/3_flink_run.py .
sudo python 1_direct_run.py
sudo python 2_dataflow_run.py
sudo python 3_flink_run.py
```

https://cloud.google.com/sdk/docs/quickstart-macos?hl=ko ./google-cloud-sdk/install.sh . ~/.bash\_profile gcloud init

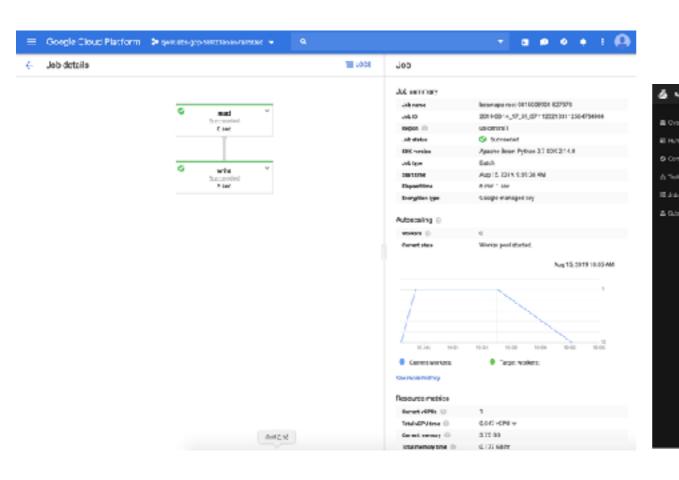


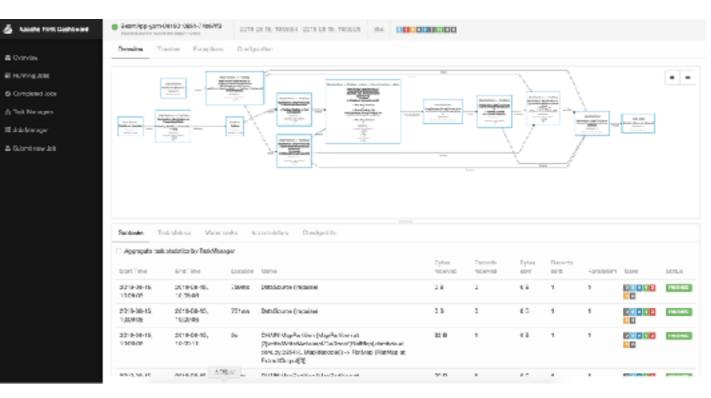


## **Pipeline**

#### 먼저 주요 개념들에 대해 짚고 넘어갑시다.

. Pipeline, Workflow graph, DAG





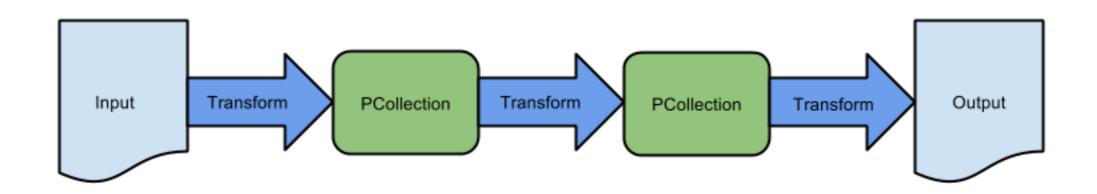
## **Pipeline**

#### 먼저 주요 개념들에 대해 짚고 넘어갑시다.

. PCollection / PTransform

```
pipeline
  | 'read' >> ReadFromText("gs://dataflow-samples/shakespeare/kinglear.txt")
  | 'format' >> beam.Map(format_message)
  | 'write' >> WriteToText("gs://da-beam-flink/out1.txt")
```

The resulting workflow graph of the above pipeline looks like this.

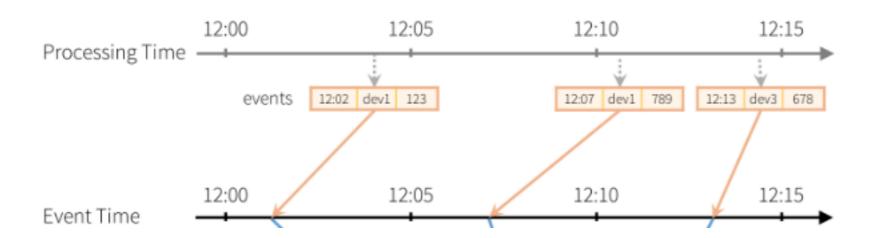


## Source

- . Bounded (ex. File). Unbounded (ex. Kafka, PubSub)

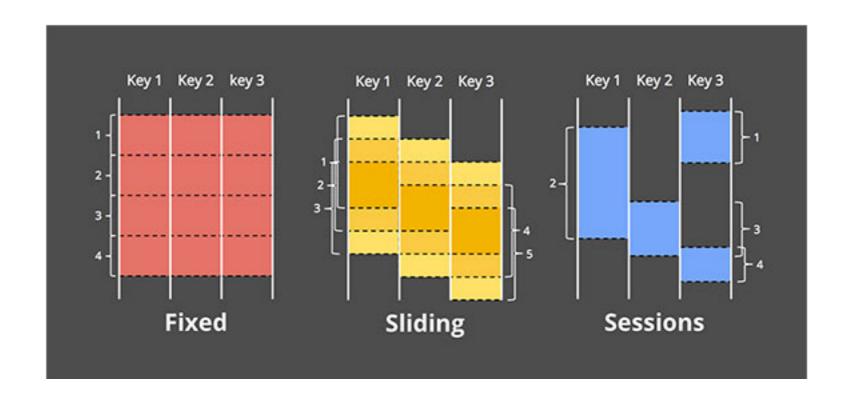
#### **Time**

- . Event Time
- . Processing Time
- . Ingestion Time



## **Window**

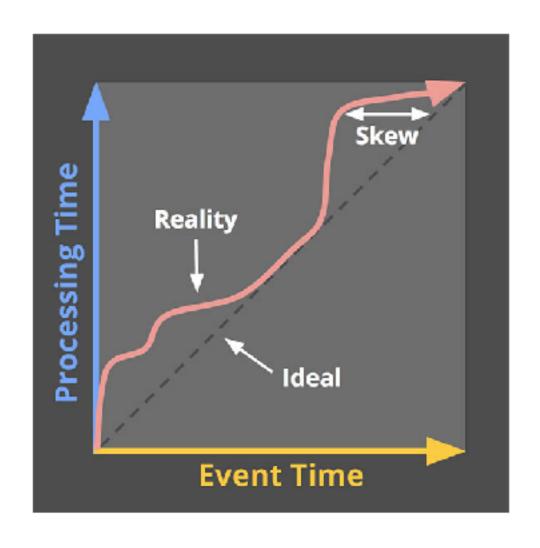
- . Tumbling (Fixed) Window
- . Sliding Window
- . Session Window
- . Global Window

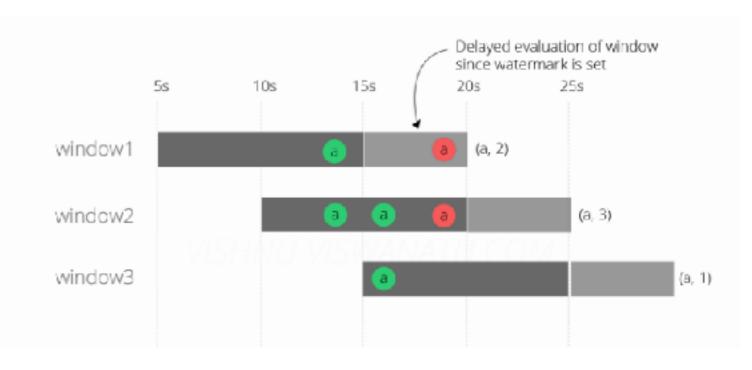


## **Irregular Time**

하지만 Event Data 는 항상 순서대로 들어오지 않고, 유실도 있습니다.

# Watermark (for drop) Late elements



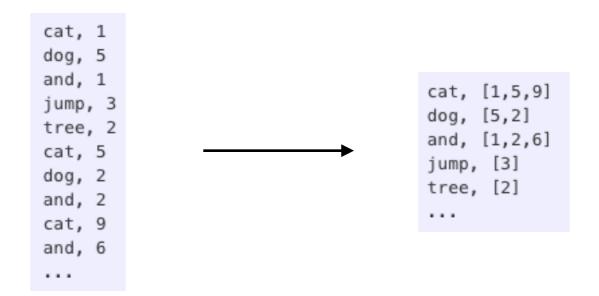


# **Trigger**

- . Event time trigger
- . Processing time trigger . Data-driven trigger (횟수)
- . Composite trigger

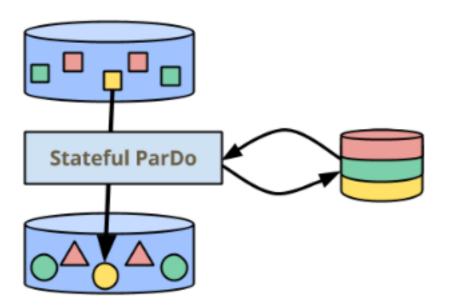
## **Transform**

- . ParDo / Map / FlatMap (N to N or M)
- . Combine, GroupByKey (aggregation)



## **Operator State (ex kafka connector offset)**

## **Keyed State**



## **Lab 1. Batch Read And Count**

File 내용을 읽고, 중복 단어를 세어봅니다

Goal : FlatMap, Map, GroupByKey, CombineGlobally 의 동작 확인

## Lab 2. Python Built-in I/O

File / Log 외에

GCP Pub/Sub, BigQuery 만 지원하고 있습니다.

다음 Lab 을 위해 Pub/Sub Topic 을 만들어봅시다.

- 1. service\_account 생성
- 2. Ingest to PubSub

## Lab 2. Streaming Read And Count

- . Timestamp 를 설정해봅시다.
- . Windowing / Trigger 조건을 변경하며 결과를 확인합시다.

Fixed / Sliding / AfterCount (ACCUMULATING / DISCARDING)

## **Lab 3. Tweet Counter**

- . twitter api 사용을 위한 키를 생성합시다.
- . tweepy to pubsub generator 를 셋업합니다.
- . processing time trigger 를 활용해서 일정 시간 마다 갯수를 집계합니다.
- . key words 를 포함하는 tweet 만 Filtering 해봅시다.

# **Lab 4. Top Trending Hashtag**

- . Hashtag 를 분리하는 DoFn 을 작성합니다.
- . Hashtag 로 GroupBy 하여 상위 tag 를 주기적으로 출력합니다.
- . State 를 활용하여 처음 발견된 tag 들의 변화를 추적합니다.

# **Lab 5. Sentimental Analysis**

- . sentimental package 를 활용하여, sentiment value 를 계산합니다.
- . 상위 hashtag 의 sentiment 평균을 정기적으로 집계합니다.